

Unidade 1 — Configurações de saída do LLM

Aplicações de Modelos de Linguagem Natural

1 Configuração da Saída do LLM

- Tamanho da saída
- Controles de amostragem
- Juntando tudo

Configurações que controlam a saída do LLM

- A maioria dos LLMs oferece diversas opções que controlam a saída gerada.
- Uma engenharia de prompt eficaz exige ajustar essas configurações de forma adequada à tarefa que se quer resolver.


Tamanho da saída

- Uma configuração importante é o número de tokens a serem gerados na resposta.
- Gerar mais tokens exige mais computação do modelo, o que leva a maior consumo de energia, tempos de resposta potencialmente mais lentos e custos mais altos.
- Reduzir o tamanho da saída não torna o LLM mais conciso em termos de estilo ou de conteúdo — apenas faz com que ele pare de prever novos tokens assim que o limite é atingido.
- Se a tarefa exige uma resposta curta, também é necessário elaborar o prompt para que ele produza esse tipo de resposta.
- A restrição do tamanho da saída é especialmente importante em algumas técnicas de prompting, como o ReAct, em que o modelo tende a continuar emitindo tokens desnecessários depois de já ter gerado a resposta desejada.

- Os LLMs não preveem, a rigor, um único token diretamente.
- Em vez disso, eles calculam uma probabilidade para cada token possível do seu vocabulário, e essas probabilidades são então amostradas para determinar qual será o próximo token produzido.
- Temperatura, top-K e top-P são as configurações mais comuns usadas para processar essas probabilidades e escolher um único token de saída.

- A temperatura controla o grau de aleatoriedade na seleção do token.
- Temperaturas mais baixas são adequadas para prompts que esperam uma resposta mais determinística, enquanto temperaturas mais altas tendem a gerar resultados mais diversos ou inesperados.
- Uma temperatura igual a 0 (*greedy decoding*, ou decodificação gulosa) é determinística: o token de maior probabilidade é sempre selecionado — embora, se dois tokens tiverem exatamente a mesma probabilidade mais alta, a forma como esse empate é resolvido possa fazer com que nem sempre se obtenha a mesma saída, mesmo com temperatura 0.
- Temperaturas próximas do valor máximo tendem a gerar saídas mais aleatórias. À medida que a temperatura aumenta, todos os tokens tendem a se tornar igualmente prováveis de serem escolhidos como o próximo token.

Figura 1 — Efeito da temperatura na distribuição de probabilidade



- Com um valor T mais alto ($T > 1$), palavras como “nervoso” têm uma probabilidade consideravelmente maior de serem escolhidas, enquanto “feliz” se torna menos dominante.
- Com um valor T mais baixo ($T < 1$), a escolha de “feliz” é quase garantida, enquanto as outras são efetivamente ignoradas.
- 75% da probabilidade corresponde a uma palavra em $T=0,25$, duas palavras em $T=1$ e quatro palavras em $T=2$.

Figura: Efeito da temperatura (T) na distribuição de probabilidade dos tokens.

Top-K, Top-P e Min-P

- Top-K e top-P (também chamado de *nucleus sampling*, ou amostragem por núcleo) são duas configurações usadas em LLMs para restringir a escolha do próximo token a um subconjunto dos tokens com maior probabilidade prevista.
- Assim como a temperatura, essas configurações controlam a aleatoriedade e a diversidade do texto gerado.
- A amostragem **top-K** seleciona os K tokens mais prováveis da distribuição prevista pelo modelo.
- Quanto maior o valor de top-K, mais criativa e variada tende a ser a saída do modelo; quanto menor o valor, mais restrita e factual ela tende a ser.
- Um top-K igual a 1 equivale à decodificação gulosa.

Figura 2 — Amostragem Top-K




Figura: Amostragem Top-K.

- Com $K=3$, os quatro tokens de menor probabilidade são descartados completamente.
- O modelo seleciona amostras apenas de “feliz”, “contente” e “animado”.

Top-P (nucleus sampling)

- A amostragem **top-P** seleciona os tokens de maior probabilidade cuja soma acumulada não ultrapasse um determinado valor (P).
- Os valores de P variam de 0 (decodificação gulosa) a 1 (todos os tokens do vocabulário do modelo).

Figura 3 — Amostragem Top-P




Figura: Amostragem Top-P.

- O modelo começa com “feliz” (56,4%).
- Adiciona “contente” (18,8%), totalizando 75,2%.
- Em seguida “animado” (13,9%), chegando a 89,1%.
- Adicionando “alegre” (5,7%), o total chega a 94,7%, o que atinge o limite de 90% — portanto, o processo termina aí.
- Como são necessários 4 tokens para atingir o limite, esses são os que são mantidos.

- A amostragem **min-P** seleciona os tokens cuja probabilidade não fique abaixo de uma fração da probabilidade do token mais provável, definida pelo parâmetro P .
- Diferente do top-P, esse limiar se ajusta dinamicamente à confiança do modelo, o que costuma evitar a inclusão de tokens irrelevantes quando a distribuição de probabilidades está mais achatada.

Figura 4 — Amostragem Min-P




Figura: Amostragem min-P.

- Se o token mais provável tiver 56,4% de probabilidade e P for 0,1, o limiar de corte fica em 5,64%.

Como escolher entre Top-K, Top-P e Min-P

- A melhor forma de escolher entre top-K, top-P e min-P é experimentar os métodos — separadamente ou combinados — e observar qual deles produz os resultados desejados.

Juntando tudo: combinando as configurações

- Na prática, temperatura, top-K e top-P raramente são usados isoladamente: é a combinação entre eles que determina o comportamento final do modelo.
- Uma temperatura alta usada sozinha, por exemplo, pode permitir que tokens muito improváveis apareçam na saída, produzindo um texto sem sentido.
- Já quando essa mesma temperatura alta é combinada com uma filtragem por top-P, é possível obter variedade criativa sem o risco de o texto se desconectar completamente do que faz sentido.

O pipeline de amostragem: fluxo mais comum

- A ordem em que os filtros de temperatura, top-K e top-P são aplicados também importa — existe mais de uma forma de organizar esse processo, chamado de *pipeline de amostragem*.
- No fluxo mais comum:
 - ① a temperatura é aplicada primeiro, reescalando a distribuição de probabilidades dos tokens;
 - ② em seguida, aplica-se a filtragem por top-K ou por top-P sobre essa distribuição já reescalada;
 - ③ por fim, o próximo token é escolhido por amostragem aleatória dentro do conjunto de tokens que restou.
- Essa abordagem em camadas permite ajustar, de forma bastante controlada, o equilíbrio entre coerência e criatividade da saída.

Um fluxo alternativo: o pipeline do llama.cpp

- Existe também um fluxo alternativo, adotado por exemplo pelo llama.cpp: nele, a filtragem por top-K/top-P ocorre primeiro, ainda sobre a distribuição de probabilidades original — sem a influência da temperatura — e só depois a temperatura é aplicada sobre o conjunto de tokens já filtrado.
- Como a ordem das operações é diferente, esse pipeline pode produzir resultados bastante distintos do primeiro, mesmo usando exatamente os mesmos valores de temperatura, top-K e top-P.

Recomendações práticas por tipo de tarefa

- **Tarefas factuais ou determinísticas** (resumir um texto, gerar código, responder perguntas): costuma funcionar melhor usar uma temperatura baixa combinada com um top-P alto. Isso mantém o foco nas respostas mais prováveis, mas ainda preserva uma escrita natural, evitando um texto excessivamente repetitivo ou mecânico.
- **Tarefas criativas** (brainstorming, redação de narrativas, textos publicitários): costuma funcionar melhor usar uma temperatura alta combinada com um top-P mais baixo. Isso permite que o modelo escolha palavras mais inesperadas, mas ainda descarta as opções realmente improváveis, evitando que o texto perca completamente o sentido.
- Em resumo: temperatura baixa + top-P generoso ajuda a evitar repetições mecânicas sem perder precisão; temperatura alta + top-P mais restrito abre espaço para respostas mais criativas, dentro de limites razoáveis.
- Essas são diretrizes gerais, não regras fixas: os melhores valores de temperatura, top-K, top-P e min-P sempre dependem do contexto específico de uso e costumam exigir ajuste experimental para cada tarefa.

- O desempenho de um LLM é bastante sensível à forma como o prompt é escrito: uma engenharia de prompt cuidadosa reduz saídas inconsistentes e alucinações, e é amplamente aplicada em chatbots, geração de conteúdo e sistemas de apoio à decisão.
- A saída de um LLM pode ser ajustada por meio de configurações como o **tamanho da saída** (número de tokens) e os **controles de amostragem** — **temperatura**, **top-K**, **top-P** e **min-P** — que juntos determinam o equilíbrio entre coerência e criatividade das respostas geradas.