

Unidade 2 — Técnicas de Prompt

Aplicações de Modelos de Linguagem Natural

- 1 Introdução
- 2 Zero-shot Prompting
- 3 Few-shot Prompting

- 1 Introdução
- 2 Zero-shot Prompting
- 3 Few-shot Prompting

O que vimos na Unidade 1

- Na Unidade 1, vimos os conceitos fundamentais da engenharia de prompt: o que é um **prompt**, como ele pode ser construído a partir de um **prompt template** (modelo de prompt) e qual é o vocabulário básico usado para descrever seus componentes — diretiva, exemplos, formatação de saída, instruções de estilo, papel/persona e informações adicionais.
- Vimos também por que a forma como um prompt é escrito afeta diretamente a qualidade da resposta gerada por um modelo de linguagem.

Desta unidade: técnicas concretas de prompting

- Nesta unidade, avançamos para **técnicas concretas de prompting** — estratégias específicas para estruturar prompts de modo a obter respostas melhores, mais precisas e mais confiáveis.
- Estudaremos quatro técnicas amplamente utilizadas na prática:
 - Duas abordagens fundamentais, que diferem principalmente pela quantidade de exemplos fornecidos ao modelo: o **zero-shot prompting** (nenhum exemplo) e o **few-shot prompting** (alguns exemplos).
 - Duas estratégias mais avançadas, voltadas para melhorar o raciocínio do modelo: o **Chain-of-Thought (CoT) prompting**, que estrutura o raciocínio em passos, e o **ReAct prompting**, que combina raciocínio com o uso de ferramentas e ações externas.
- Para cada técnica, veremos o que ela é, como funciona, exemplos práticos de aplicação, e suas principais vantagens e limitações. Nesta apresentação, veremos em detalhe as duas primeiras: zero-shot e few-shot prompting.

- 1 Introdução
- 2 Zero-shot Prompting
- 3 Few-shot Prompting

O que é zero-shot prompting

- **Zero-shot prompting** é a abordagem em que o modelo realiza uma tarefa sem receber nenhum exemplo prévio de como executá-la.
- O modelo se apoia unicamente no conhecimento adquirido durante o seu pré-treinamento — relações semânticas, estrutura da linguagem e raciocínio contextual — para interpretar a instrução e gerar uma resposta.
- Como não há exemplos de saída no prompt, o modelo precisa inferir o que se espera dele apenas a partir do texto da instrução.

Zero-shot prompting e o machine learning tradicional

- Diferente do machine learning tradicional, que depende de grandes conjuntos de dados rotulados para treinar um modelo em uma tarefa específica, o zero-shot prompting aproveita a capacidade de generalização de um modelo já pré-treinado.
- Isso permite realizar tarefas como classificação de texto, raciocínio lógico e geração de conteúdo sem que seja necessário nenhum dado de treinamento específico para o domínio da tarefa.
- Por outro lado, a eficácia dessa abordagem depende muito da clareza do prompt: instruções ambíguas ou mal formuladas tendem a gerar respostas imprecisas ou inconsistentes.

- O modelo utiliza o conhecimento linguístico, as relações conceituais e as associações contextuais que adquiriu durante o pré-treinamento para interpretar o prompt e gerar uma resposta adequada, sem depender de treinamento adicional ou de exemplos explícitos para a tarefa em questão.
- Ou seja, a resposta é gerada unicamente a partir da instrução fornecida e do conhecimento interno já acumulado pelo modelo.
- Quanto mais completo e abrangente for esse conhecimento, e quanto maior for a capacidade do modelo de generalizar para situações novas, melhor tende a ser o resultado do zero-shot prompting.

Exemplo 1 — Classificação por zero-shot

Prompt

“Categorize o seguinte texto como positivo ou negativo:

‘Este filme foi absolutamente fantástico! A atuação foi excelente, o roteiro foi envolvente e os efeitos especiais foram impressionantes.’”

Mesmo sem qualquer treinamento prévio específico para análise de sentimento, o modelo deve responder “positivo”.

Exemplo 2 — Tradução por zero-shot

Prompt

“Traduza a frase a seguir para o francês:
‘Bom dia, como você está?’”

Mesmo sem receber nenhum exemplo de tradução, o modelo consegue traduzir corretamente a frase, pois foi treinado com grandes volumes de dados multilíngues.

Exemplo 3 — Geração de conteúdo por zero-shot

Prompt

“Escreva um poema curto sobre o outono.”

O modelo produz um poema original apenas a partir da instrução, sem receber nenhum exemplo de poema.

Exemplo 4 — Análise de texto por zero-shot

Prompt

“Destaque os principais temas do trecho abaixo:

‘Toda vez que visito a casa onde cresci, sinto uma mistura estranha de alegria e tristeza. As paredes ainda guardam o cheiro do café da manhã que minha avó preparava, mas ela já não está mais lá para prepará-lo. Foi há tanto tempo, e ainda assim parece que foi ontem.’”

Mesmo sem exemplos prévios, o modelo consegue identificar temas como nostalgia, a passagem do tempo e a natureza agri-doce da memória no trecho apresentado.

Vantagens do zero-shot prompting

- **Flexibilidade:** o modelo consegue realizar uma ampla variedade de tarefas sem precisar de nenhum ajuste específico.
- **Dispensa treinamento específico:** elimina a necessidade de conjuntos de dados rotulados, reduzindo o custo de desenvolvimento.
- **Implantação rápida:** facilita testes e implementação ágil em diferentes domínios.
- **Avaliação da generalização do modelo:** permite avaliar a capacidade do modelo de compreender e se adaptar a desafios diferentes daqueles vistos durante o treinamento.

Limitações do zero-shot prompting

- **Precisão:** tende a ser menor do que a de modelos ajustados especificamente para a tarefa (fine-tuned), já que não há otimização para o caso em questão, a interpretação do prompt pelo modelo pode variar, e tarefas muito especializadas exigem uma compreensão mais profunda que o zero-shot nem sempre consegue capturar.
- **Sensibilidade ao prompt:** pequenas variações na forma como o prompt é escrito podem alterar significativamente a interpretação e a resposta do modelo, e instruções pouco claras tendem a gerar respostas inconsistentes ou irrelevantes.
- **Viés:** por depender de modelos pré-treinados, o zero-shot está sujeito a vieses presentes nos dados de treinamento, como vieses demográficos e culturais, viés de recência (favorecer informações mais recentes em detrimento do contexto histórico) e reforço de estereótipos.

- 1 Introdução
- 2 Zero-shot Prompting
- 3 Few-shot Prompting

O que é few-shot prompting

- **Few-shot prompting** aprimora a capacidade do modelo de executar uma tarefa fornecendo alguns exemplos — chamados de demonstrações — dentro do próprio prompt.
- Diferente do zero-shot, que depende exclusivamente do conhecimento pré-treinado, o few-shot usa essas demonstrações como orientação contextual para melhorar a precisão e a relevância da resposta.
- Essa técnica ocupa uma posição intermediária entre o zero-shot (nenhum exemplo) e o fine-tuning completo (que exige grandes conjuntos de dados rotulados), permitindo adaptar o modelo a uma tarefa específica sem abrir mão da flexibilidade típica do prompting.

Como funciona — as demonstrações

- O princípio central do few-shot prompting é incluir, no próprio prompt, demonstrações específicas da tarefa que se quer que o modelo execute.
- Essas demonstrações funcionam como instruções implícitas que orientam o comportamento do modelo e costumam apresentar três características:
 - cada demonstração traz um par de **entrada e saída** (por exemplo, uma pergunta e sua resposta esperada);
 - há **consistência de formato** entre os exemplos, o que ajuda o modelo a reconhecer o padrão estrutural do prompt;
 - os exemplos têm **relevância** para a tarefa-alvo, garantindo que o modelo extraia informações realmente úteis.

Exemplo 5 — Classificação de texto por few-shot prompting

Prompt

Avaliação: “A comida estava deliciosa e o atendimento foi excelente.” → Positiva

Avaliação: “Muito demorado e o prato veio errado.” → Negativa

Classifique esta nova avaliação com base nos exemplos acima:

{NOVA_AVALIACAO}

O modelo aprende o padrão a partir de avaliações já classificadas e o aplica a uma nova avaliação.

Exemplo 6 — Tradução automática por few-shot prompting

Prompt

Inglês: "Hello, how are you?" → Espanhol: "Hola, ¿cómo estás?"

Inglês: "See you tomorrow." → Espanhol: "Nos vemos mañana."

Traduza a frase a seguir para o espanhol, seguindo o padrão dos exemplos acima:

{FRASE_EM_INGLES}

Exemplo 7 — Geração de código por few-shot prompting

Prompt

Entrada: soma(2, 3) → Saída: 5

Entrada: soma(10, 5) → Saída: 15

Complete a função a seguir, seguindo o padrão dos exemplos acima:

```
def soma(a, b):  
    # complete aqui
```

O modelo completa a função com base nos pares de entrada e saída fornecidos.

Exemplo 8 — Perguntas e respostas por few-shot prompting

Prompt

Pergunta: “Qual é a capital da França?” → Resposta: “Paris.”

Pergunta: “Qual é a capital do Japão?” → Resposta: “Tóquio.”

Responda à pergunta a seguir, seguindo o padrão dos exemplos acima:

{NOVA_PERGUNTA}

O modelo responde a novas perguntas factuais com base em exemplos de perguntas e respostas fornecidos anteriormente.

Vantagens do few-shot prompting

- **Maior precisão:** ao se apoiar em exemplos concretos, o modelo tende a produzir respostas mais precisas do que no zero-shot.
- **Melhor adaptação à tarefa:** o modelo consegue aprender padrões específicos a partir de um número pequeno de exemplos.
- **Maior controle do usuário:** ao escolher cuidadosamente as demonstrações incluídas no prompt, o usuário pode ajustar o comportamento do modelo de forma mais precisa.

Limitações do few-shot prompting

- **Sensibilidade aos exemplos:** o desempenho do modelo depende fortemente da qualidade, da relevância e até da ordem dos exemplos escolhidos.
- **Maior custo em tokens:** incluir exemplos no prompt aumenta o tamanho da entrada, o que pode elevar o custo computacional.
- **Desempenho nem sempre superior:** apesar de seus benefícios, o few-shot prompting nem sempre supera o desempenho de modelos ajustados especificamente (fine-tuned) para a tarefa.

- O **zero-shot prompting** realiza a tarefa sem nenhum exemplo prévio, apoiando-se apenas no conhecimento adquirido no pré-treinamento — é flexível e rápido de implantar, mas mais sensível à clareza do prompt e a vieses do modelo.
- O **few-shot prompting** inclui algumas demonstrações no próprio prompt, permitindo que o modelo use *in-context learning* para reconhecer padrões, inferir a tarefa, generalizar e aplicar esse padrão a uma nova entrada — tende a ser mais preciso, mas tem maior custo em tokens e depende da qualidade dos exemplos escolhidos.
- Ambas as técnicas ocupam posições diferentes entre a ausência total de exemplos e o fine-tuning completo, e serão a base para as técnicas mais avançadas que veremos a seguir: Chain-of-Thought e ReAct prompting.